数据分析数学 I)

目录

数据分析 **2**

数据的整理与代表值 2

数据的散布 3

分散与标准偏差 5

数据的相关 6

外れ値（离群值） 8

Ⓕ说检定 9

数据分析

数据的整理与代表值

PART1 变量与数据

变量 像身高、气温、考试分数这样，用数量表示人或事物特征的量，叫做**变量**。

数据 变量的观测值、测量值或记录值的集合，叫做**数据**。

整理数据的方法 教材中介绍了两种重要的整理方式：

- **频数分布表**
- **直方图**

组距与频数 把数据按一定区间分组后，每个区间叫做一个**组**（或阶级），每组中数据的个数叫做该组的**频数**。每组区间的长度叫做**组距**。

相对频数 某一组的频数除以数据总数，得到该组的**相对频数**：

$$\text{相对频数} = \frac{\text{该组频数}}{\text{总数据个数}}$$

Point Pickup

- 变量是“可以取不同数值的量”，数据是“这些值的集合”。
- 直方图是频数分布表的图形化表示。
- 相对频数反映的是“这一组占整体的比例”。

PART2 平均数、中位数、众数

平均数 设一组数据为

$$x_1, x_2, \ldots, x_n$$

则它们的平均数为

$$\bar{x} = \frac{x_1 + x_2 + \cdots + x_n}{n}$$

平均数反映的是数据的整体水平。

中位数 把数据按从小到大的顺序排列后：

- 若数据个数为奇数，中间那个数就是**中位数**
- 若数据个数为偶数，中间两个数的平均数就是**中位数**

众数 在一组数据中，出现次数最多的数叫做**众数**。

分组数据中的代表值 若数据被整理成频数分布表，则常用每一组的**组中值**（组的中点）来近似表示这一组。此时可以用组中值与频数来近似求平均数。众数也常用**频数最大的组的组中值**来近似表示。

Point Pickup

- 平均数受所有数据影响最大。
- 中位数反映“中间位置”，不太容易被极端值拉动。
- 众数反映“最常出现的值”。
- 分组数据中，常用组中值来近似计算。

数据的散布

PART1 极差

极差 数据的**极差**定义为：

$$\text{极差} = \text{最大值} - \text{最小值}$$

极差越大，通常说明数据的散布程度越大。

极差的特点 极差计算简单，但它只利用了最大值和最小值。因此，如果数据中有特别大或特别小的极端值，极差会受到很大影响。

Point Pickup

- 极差是描述散布最直观的量。
- 但极差非常容易受到极端值影响。

PART2 四分位数与四分位距

四分位数 把数据按从小到大排列后，将其大致分成四等分位置的值，叫做**四分位数**。

- 第 1 四分位数：Q_1
- 第 2 四分位数：Q_2
- 第 3 四分位数：Q_3

其中，Q_2 就是**中位数**。

四分位距 第 3 四分位数与第 1 四分位数之差：

$$Q_3 - Q_1$$

叫做**四分位距**。

它表示中间约 50% 数据的分布范围。

四分位距的特点 与极差相比，四分位距不太容易受到极端值影响。因此在比较多个数据组的散布程度时，四分位距往往更稳定。

四分位偏差 教材还提到，把四分位距除以 2 得到的量，叫做**四分位偏差**：

$$\frac{Q_3 - Q_1}{2}$$

Point Pickup

- Q_2 就是中位数。
- 四分位距反映的是“中间一半数据”的散布情况。
- 四分位距比极差更不容易受极端值影响。

PART3 箱线图

箱线图 用最小值、第 1 四分位数、中位数、第 3 四分位数、最大值五个量，把数据分布画成一个图，这样的图叫做**箱线图**。

箱线图由：

- 最小值
- Q_1
- 中位数 Q_2
- Q_3
- 最大值

构成。

箱线图的作用 箱线图可以直观反映：

- 数据分布的大致范围
- 数据是否偏向某一侧
- 中间部分是否集中

- 多组数据之间分布差异

因此，箱线图很适合比较多组数据的分布情况。

Point Pickup

- 箱线图的核心是五数概括：最小值、Q_1、中位数、Q_3、最大值。
- 箱线图尤其适合比较多个数据集。

分散与标准偏差

PART1 偏差

偏差 设数据为

$$x_1, x_2, \ldots, x_n$$

平均数为

$$\bar{x}$$

则每个数据与平均数的差

$$x_1 - \bar{x}, \quad x_2 - \bar{x}, \quad \ldots, \quad x_n - \bar{x}$$

叫做各数据的**偏差**。

偏差的正负

- 若某个数据大于平均数，则对应偏差为正
- 若某个数据小于平均数，则对应偏差为负

偏差平均的特点 所有偏差的平均总是 0，因此不能直接用“偏差的平均”来衡量散布大小。

Point Pickup

- 偏差表示“离平均值有多远”。
- 但偏差有正有负，直接平均后会互相抵消。

PART2 分散

分散 为了避免偏差正负抵消，把偏差平方后再求平均，就得到**分散**：

$$s^2 = \frac{1}{n}\left\{(x_1 - \bar{x})^2 + (x_2 - \bar{x})^2 + \cdots + (x_n - \bar{x})^2\right\}$$

分散越大，说明数据离平均值越远，散布越大。

分散的意义 分散利用了全部数据，因此比极差、四分位距更全面地反映散布程度。

Point Pickup

- 分散是“偏差平方的平均”。
- 分散越大，数据越分散。
- 分散用到了所有数据，因此信息更完整。

PART3 标准偏差

标准偏差 分散的平方根叫做**标准偏差**：

$$s = \sqrt{s^2}$$

意义 标准偏差和分散一样，都表示数据的散布程度。与分散相比，标准偏差的单位与原数据相同，因此更直观。

极端值的影响 教材特别说明：如果数据中有和其他值相差很大的值，那么分散和标准偏差通常也会变大。

Point Pickup

- 标准偏差是分散的平方根。
- 它与原数据单位相同，因此更容易解释。
- 极端值会明显拉大分散和标准偏差。

数据的相关

PART1 散点图与相关关系

散点图 当想研究两个变量之间是否有关联时，可以把每组数据 (x, y) 当作坐标平面上的一个点画出来。这种图叫做**散点图**。

正相关与负相关

- 若一个变量增大时，另一个变量也倾向于增大，则称有**正相关**
- 若一个变量增大时，另一个变量倾向于减小，则称有**负相关**
- 若看不出明显倾向，则称**没有相关**

相关强弱 在散点图中，点越接近一条直线，通常说明相关越强；点越分散，说明相关越弱。

Point Pickup

- 散点图是研究两个变量关系最直观的工具。
- 相关有“正相关”“负相关”“无相关”。
- 点越接近直线，相关通常越强。

PART2 共分散

共分散 对于成对数据

$$(x_1, y_1), (x_2, y_2), \ldots, (x_n, y_n)$$

设 x 的平均数为 $\bar{x}$，y 的平均数为 $\bar{y}$，则

$$s_{xy} = \frac{1}{n}\{(x_1 - \bar{x})(y_1 - \bar{y}) + \cdots + (x_n - \bar{x})(y_n - \bar{y})\}$$

叫做**共分散**。

共分散的符号

- 正相关时，共分散通常为正
- 负相关时，共分散通常为负
- 无明显相关时，共分散接近 0

局限 共分散会受到变量单位和数据散布程度影响，因此不能直接用来比较“相关强弱”。

Point Pickup

- 共分散能判断“正相关还是负相关”。
- 但它不能单独用来公平比较相关强弱。

PART3 相关系数

相关系数 把共分散除以两个变量标准偏差的乘积，得到**相关系数**：

$$r = \frac{s_{xy}}{s_x s_y}$$

取值范围 相关系数满足

$$-1 \leq r \leq 1$$

解释

- r 越接近 1，正相关越强
- r 越接近 -1，负相关越强
- r 越接近 0，相关越弱

注意 相关系数接近 0，并不一定表示两个变量毫无关系，只能说**线性相关较弱**。

Point Pickup

- 相关系数是衡量线性相关强弱的标准化指标。
- r 的正负表示方向，大小表示强弱。
- $|r|$ 越大，相关越强。

外れ値（离群值）

PART1 外れ値的定义

外れ値 在数据中，如果某个值和其他值相比显得特别偏离，就把它称为**外れ値**（离群值）。

教材中的判定标准 设第 1 四分位数为 Q_1，第 3 四分位数为 Q_3，则：

$$Q_1 - 1.5(Q_3 - Q_1)$$

以下的值，或

$$Q_3 + 1.5(Q_3 - Q_1)$$

以上的值，定义为外れ値。

意义 这个标准是基于四分位距建立的，因此和箱线图密切相关。

Point Pickup

- 外れ値就是明显偏离整体的数据。
- 判定时用到四分位距，而不是极差。

PART2 外れ値的影响

影响 教材指出，若数据中包含外れ値，那么以下统计量通常会受到较大影响：

- 极差
- 平均数

- 分散
- 标准偏差
- 相关系数

处理思路 在分析数据时，应先判断是否存在外れ值，再决定是否需要把它单独讨论，或者比较“包含外れ值”和“去掉外れ值”后的结果。

Point Pickup

- 外れ值对平均数和分散类统计量影响特别大。
- 遇到明显异常值时，要有意识地先检查它。

Ⓕ说检定

PART1 Ⓕ说检定的想法

基本想法 当我们想根据观察结果判断某种主张是否合理时，可以使用Ⓕ**说检定**。

教材中的核心思想是：

1. 先提出希望主张的Ⓕ说
2. 再提出与之相反的Ⓕ说
3. 在“相反Ⓕ说成立”的前提下，计算当前结果出现的概率
4. 再把这个概率和预先规定的基准概率比较

常用基准概率 教材指出，常见的基准概率通常取：

$$0.05 \quad (5\%)$$

或

$$0.01 \quad (1\%)$$

Point Pickup

- Ⓕ说检定不是“直接证明自己想法正确”。
- 而是先检验“反面的说法还能不能成立”。

PART2 判断规则

若结果很罕见 如果在“相反Ⓕ说成立”的前提下，当前结果发生的概率小于基准概率，那么就认为这种结果**太罕见**，从而判断相反Ⓕ说不合理。

这时，就可以支持原先想主张的Ⓕ说。

若结果不够罕见 如果这个概率没有小于基准概率，那么就**不能判断相反Ⓕ说错误**。此时只能说：原来的主张**还不能被认为成立**。

重要注意 “不能否定相反Ⓕ说”并不代表“相反Ⓕ说一定正确”；同样，也不代表“原Ⓕ说一定错误”。

Point Pickup

- 小于基准概率 ⇒ 可以否定相反Ⓕ说，支持原Ⓕ说。
- 不小于基准概率 ⇒ 不能支持原Ⓕ说，但也不能说它一定错。

PART3 教材中的典型例子

例 1：球队实力 如果两支球队原本被认为实力相当，却出现了某队连续 5 连胜，就可以在“双方实力相同”的前提下，计算“5 连胜”发生的概率。若该概率小于 0.05，就可以认为“双方实力相同”这一假设不合理。

例 2：硬币问题 如果一枚硬币投 6 次出现正面 5 次，也可以在“这是一枚公平硬币”的前提下，考察这种结果出现的概率，再决定是否能说“这枚硬币更容易出正面”。

本质 这些例子说明：Ⓕ说检定的关键不在于结果本身大不大，而在于**这个结果在原假设下是否罕见**。

Point Pickup

- Ⓕ说检定的关键句式是：“如果原本没有差异，这样的结果容易发生吗?”
- 如果“不太可能发生”，就有理由怀疑原来的假设。

总结

“数据分析”这一部分的核心内容可以概括为：

1. 数据整理部分：掌握频数分布表、直方图、平均数、中位数、众数。
2. 数据散布部分：掌握极差、四分位数、四分位距和箱线图。
3. 分散部分：掌握偏差、分散、标准偏差的意义与计算公式。
4. 相关部分：掌握散点图、正负相关、共分散与相关系数。
5. 外れ値部分：掌握离群值的判定方式及其对统计量的影响。
6. Ⓕ说检定部分：掌握“提出Ⓕ说—比较概率—作出判断”的基本思路。