

20 データの代表値と散らばり

基本事項

① データの整理

① 度数分布表

- 階級 …… データの値の範囲を区切った区間。
- 階級の幅 …… 階級としての区間の幅。
- 階級値 …… 階級の真ん中の値。
- 度数 …… 各階級に入るデータの個数。
- 度数分布表 …… 各階級に度数を対応させた表。

度数分布表	
階級値	度数
x_1	f_1
x_2	f_2
$\vdots$	$\vdots$
x_r	f_r
計	n

② 相対度数分布表

- 相対度数 …… 各階級の度数の全体に対する割合。
- 累積度数 …… 各階級に対し、度数を最初の階級からその階級の値まで合計したもの。
- 累積相対度数 …… 相対度数についての累積度数。

x_i の相対度数は $\frac{f_i}{n}$

解 説

<データ>

テストの得点などのように、ある集団を構成する人や物の特性を数量的に表す量を **変量** といい、調査や実験などで得られた変量の観測値や測定値の集まりを **データ** という。データを構成する観測値や測定値の個数を、そのデータの **大きさ** という。

<相対度数分布表>

各階級に累積度数を対応させた表を **累積度数分布表** といい、各階級に相対度数を対応させた表を **相対度数分布表** という。

例 ある卵 105 個の重さ（単位は g）を測り、階級の幅を 5 g としたときの度数分布表が [表 1] のとき、累積度数分布表は [表 2]、相対度数分布表は [表 3] のようになる。

[表 1] 度数分布表

階 級 (g)	度数
40 以上～45 未満	2
45 ～50	8
50 ～55	15
55 ～60	36
60 ～65	34
65 ～70	6
70 ～75	3
75 ～80	1
計	105

[表 2] 累積度数分布表

階 級 (g)	累積度数
45 未満	2
50	10
55	25
60	61
65	95
70	101
75	104
80	105

[表 3] 相対度数分布表

階 級 (g)	相対度数
40 以上～45 未満	0.02
45 ～50	0.08
50 ～55	0.14
55 ～60	0.34
60 ～65	0.32
65 ～70	0.06
70 ～75	0.03
75 ～80	0.01
計	1.00

[表 2] の累積度数は 2, 2+8 (=10), 2+8+15 (=25), ……

[表 3] の相対度数は $\frac{2}{105}$ ($\div 0.02$), $\frac{8}{105}$ ($\div 0.08$), ……

データの分析

データの代表値と散らばり
分散と標準偏差，相関係数

20

21

例題一覧

レベル
▼

レベル
▼

20 ☒ **基本** 171 度数分布表，ヒストグラム

①

☒ **基本** 172 平均値，中央値の求め方

①

☒ **基本** 173 平均値の問題

③

☒ **基本** 174 中央値がとりうる値

③

☒ **基本** 175 四分位数，四分位範囲

①

☒ **基本** 176 箱ひげ図から読み取れること

③

21 ☒ **基本** 177 分散と標準偏差

②

☒ **基本** 178 平均値・分散

③

☒ **基本** 179 データの修正による平均値

③

・分散の変化

☒ **基本** 180 変数を変換したときの平均値

②

・分散

☒ **基本** 181 平均値・分散の計算

②

(変数の変換利用)

☒ **基本** 182 散布図と相関関係

①

☒ **基本** 183 相関係数

①

☒ **基本** 184 相関係数による分析

③

☒ **重要** 185 変数を変換したときの相関係数

④

コラム一覧

p.278 補足事項 データの分析と代表値

p.289 参考事項 はずれ値

基本 例題 171 度数分布表, ヒストグラム



次のデータは, ある月の A 市の毎日の最高気温の記録である。

20.7 20.1 14.5 10.9 12.1 19.1 16.3 13.1 14.6 20.2
23.2 14.3 20.1 17.4 11.2 7.4 11.5 16.5 19.9 18.1
25.5 14.2 10.1 16.7 16.7 19.9 15.7 15.4 23.4 20.1 (単位は℃)

- (1) 階級の幅を 2℃ として, 度数分布表を作れ。ただし, 階級は 6℃ から区切り始めるものとする。
- (2) (1) で作った度数分布表をもとにして, ヒストグラムをかけ。


p.268 基本事項 ①, p.269 基本事項 ②

指針▷ (1) 階級の区切り始めと階級の幅から, 各階級に入るデータの数を数え, 表にする。
(2) (1) の 度数分布表 をもとに, 柱状のグラフにして表す。ヒストグラムの各長方形の高さは, 各階級の度数を表す。

解 答

(1)

階級 (℃)	度数
6 以上 8 未満	1
8 ~ 10	0
10 ~ 12	4
12 ~ 14	2
14 ~ 16	6
16 ~ 18	5
18 ~ 20	4
20 ~ 22	5
22 ~ 24	2
24 ~ 26	1
計	30



◀ 6℃ 以上 8℃ 未満からスタートし, 最高気温 25.5℃ が入る 24℃ 以上 26℃ 未満まで 10 個の階級に分ける。

検討 階級の分け方

度数分布表の階級の幅は, データ全体の傾向がよく表されるように適切な大きさを選ぶことが大切である。
30~500 程度の大きさのデータに対して, 自分で階級を分ける場合は, 階級の数 を 6~10 程度にすると, 資料の特徴をつかみやすい。

練習

次のデータは, ある野球チームの選手 30 人の体重である。

① 171

91 84 74 75 83 78 95 74 85 75
96 89 77 76 70 90 79 84 86 77
80 78 87 73 81 78 66 83 73 70 (単位は kg)

- (1) 階級の幅を 5 kg として, 度数分布表を作れ。ただし, 階級は 65 kg から区切り始めるものとする。
- (2) (1) で作った度数分布表をもとにして, ヒストグラムをかけ。

基本事項

② ヒストグラム

ヒストグラム……度数分布表に整理された資料を柱状のグラフで表したもの。

③ データの代表値

① 平均値 $\bar{x}$

大きさ n のデータの値を $x_1, x_2, \dots, x_n$ とするとき

$$\bar{x} = \frac{1}{n}(x_1 + x_2 + \dots + x_n)$$

② 中央値(メジアン)

データを値の大きさの順に並べたとき、中央の位置にくる値。

注意 データの大きさが偶数のときは、中央の2つの値の平均値を中央値とする。

③ 最頻値(モード) データにおいて、最も個数の多い値。

注意 データが度数分布表に整理されているときは、度数が最も大きい階級の階級値を最頻値とする。


解説

<ヒストグラム>

度数分布表に整理された資料を柱状のグラフで表したものをヒストグラムという。右の図は、前ページの度数分布表([表1])をもとにしたヒストグラムである。

ヒストグラムの各長方形の高さは各階級の度数を表し、長方形の面積は各階級の度数に比例している。したがって、長方形の面積の和を見ると、ある範囲にあるものが何%ぐらいあるかがだいたいわかる。

ヒストグラム



<代表値>

データ全体の特徴を適当な1つの数値で表すとき、その数値をデータの代表値という。よく用いられる代表値として、平均値、中央値、最頻値がある。

大きさ n のデータの値を $x_1, x_2, \dots, x_n$ とするとき、それらの総和を n で割ったものを、データの平均値といい、 $\bar{x}$ で表す。

例 データ 2, 3, 5, 6 の平均値は $\frac{1}{4}(2+3+5+6)=4$

データ 1, 3, 6, 7, 8 の中央値は 6

データ 2, 3, 6, 8 の中央値は $\frac{3+6}{2}=4.5$ ◀ データの大きさが偶数の場合

データ 1, 2, 3, 3, 3, 3, 4, 4 の最頻値は 3

例 (データが度数分布表に整理されているときの最頻値の例)

前ページの[表1]では、度数が最も大きい階級は55~60であるから、最頻値は

$$\frac{55+60}{2}=57.5 \text{ (g)}$$

基本 例題 173 平均値の問題



右の表は、あるクラス 10 人について行われた数学のテストの得点の度数分布表である。得点はすべて整数とする。

得点の階級(点)	人数
30 以上 40 未満	1
40 ~ 50	2
50 ~ 60	4
60 ~ 70	3
計	10

- (1) このデータの平均値のとりうる値の範囲を求めよ。
- (2) 10 人の得点の平均点は 54.3 点であり、各得点は 69, 65, 62, 57, 55, 55, 53, 48, 42, x (単位は点) であった。 x の値を求めよ。

基本 172

指針▷ (1) データの平均値の最小値は $\frac{(\text{各階級の値の最小値}) \times (\text{各階級の人数}) \text{ の和}}{10}$

データの平均値の最大値は $\frac{(\text{各階級の値の最大値}) \times (\text{各階級の人数}) \text{ の和}}{10}$

参考 平均値を a として、合計点の範囲の不等式を作ってもよい。

$$(\text{各階級の値の最小値}) \times (\text{各階級の人数}) \text{ の和} \leq 10a \leq (\text{各階級の値の最大値}) \times (\text{各階級の人数}) \text{ の和}$$

(2) 合計点についての方程式を作る。……… !

解 答

(1) データの平均値が最小となるのは、データの各値が各階級の値の最小の値となるときであるから

$$\frac{1}{10}(30 \times 1 + 40 \times 2 + 50 \times 4 + 60 \times 3) = 49$$

データの平均値が最大となるのは、データの各値が各階級の値の最大の値となるときであるから

$$\frac{1}{10}(39 \times 1 + 49 \times 2 + 59 \times 4 + 69 \times 3) = 58$$

よって 49 点以上 58 点以下

別解 [データの平均値の最大値を求める別解]

データの平均値が最大となるのは、データの各値が最小の値よりそれぞれ 9 点だけ大きいときであるから、平均点も 9 点高くなり $49 + 9 = 58$

(2) 合計点を考えると

! $69 + 65 + 62 + 57 + 55 + 55 + 53 + 48 + 42 + x = 54.3 \times 10$

よって $x + 506 = 543$ ゆえに $x = 37$

◀ 得点は整数であるから「30 以上 40 未満」の階級において、最大の値は 39 である。

◀ $39 = 30 + 9$, $49 = 40 + 9$, $59 = 50 + 9$, $69 = 60 + 9$ であるから、平均値の最大値は

$$49 + \frac{1}{10} \times 9(1 + 2 + 4 + 3)$$

練習

③ 173

右の表は、8 人の生徒について行われたテストの得点の度数分布表である。得点はすべて整数とする。

- (1) このデータの平均値のとりうる値の範囲を求めよ。
- (2) 8 人の得点の平均点は 52 点であり、各得点は 34, 42, 43, 46, 57, 58, 65, x (単位は点) であった。 x の値を求めよ。

得点の階級(点)	人数
20 以上 40 未満	1
40 ~ 60	5
60 ~ 80	2
計	8

基本 例題 172 平均値, 中央値の求め方



5章

20

データの代表値と散らばり

次のデータは, A 班 5 人, B 班 6 人の, 10 点満点のテストの結果である。

A 班: 5, 7, 8, 4, 9 B 班: 7, 10, 9, 4, 8, 6 (単位は点)

- (1) A 班のデータの平均値と B 班のデータの平均値をそれぞれ求めよ。ただし, 小数第 2 位を四捨五入せよ。
- (2) A 班と B 班を合わせた 11 人のデータの平均値を求めよ。
- (3) A 班のデータの中央値と B 班のデータの中央値をそれぞれ求めよ。

p.269 基本事項 ③

指針▷ (1), (2) 平均値 → 変量 x のデータの値が $x_1, x_2, \dots, x_n$ であるとき,

$$\text{このデータの平均値 } \bar{x} \text{ は } \bar{x} = \frac{1}{n}(x_1 + x_2 + \dots + x_n)$$

- (3) データを値の **大きさの順** (小 → 大) に並べ替え, 中央の位置にくる値を **中央値** とする。このとき, 次のようにデータの大きさが奇数であるか, 偶数であるかに分けて考える。

データの大きさが奇数



この値が中央値

データの大きさが偶数



中央の 2 つの値の平均が中央値

解 答

- (1) A 班のデータの平均値は

$$\frac{1}{5}(5+7+8+4+9) = \frac{33}{5} = 6.6 \text{ (点)}$$

B 班のデータの平均値は

$$\frac{1}{6}(7+10+9+4+8+6) = \frac{44}{6} \div 7.3 \text{ (点)}$$

- (2) $\frac{1}{11}(33+44) = 7 \text{ (点)}$

- (3) A 班のデータを小さい方から順に並べると

4, 5, 7, 8, 9

3 番目が中央値であるから 7 点

B 班のデータを小さい方から順に並べると

4, 6, 7, 8, 9, 10

3 番目と 4 番目の平均をとって, 中央値は

$$\frac{7+8}{2} = 7.5 \text{ (点)}$$

◀ データの総和
データの大きさ

◀ (1) から, 11 人のデータの
総和は $33+44$

◀ データの大きさが奇数。

◀ データの大きさが偶数。

練習

次のデータは 10 人の生徒の 20 点満点のテストの結果である。

6, 5, 20, 11, 9, 8, 15, 12, 7, 17 (単位は点)

- (1) このデータの平均値を求めよ。 (2) このデータの中央値を求めよ。

① 172

基本事項

① データの散らばりと四分位範囲

範囲，四分位範囲，四分位偏差は，データの散らばりの度合いを表す1つの量。

① 範囲

データの最大値と最小値の差。

② 四分位数

データを値の大きさの順に並べたとき，4等分する位置にくる3つの値。


小さい方から，第1四分位数，第2四分位数，第3四分位数 といい，これらを順に Q_1 ， Q_2 ， Q_3 で表す。第2四分位数は中央値である。

③ 四分位範囲，四分位偏差

四分位範囲 $Q_3 - Q_1$ ，四分位偏差 $\frac{Q_3 - Q_1}{2}$

④ 箱ひげ図

データの最小値，第1四分位数，中央値，第3四分位数，最大値を箱と線(ひげ)で表現する図。なお，平均値を記入することもある。




解説

<範囲>

例1 10点満点のテストのデータ 3, 4, 4, 5, 6, 7, 8, 8, 8, 9, 10
最小値は3，最大値は10であるから，範囲は $10 - 3 = 7$ である。

<四分位数の求め方>

- 四分位数を求めるときは，以下のようにするとよい。
- 1 まず，データを小さい方から順に左から並べる。
 - 2 左半分のデータを下位のデータ，右半分のデータを上位のデータとする。
 - 3 下位のデータの中央値(=第1四分位数 Q_1)，上位のデータの中央値(=第3四分位数 Q_3)を求める。



注意 四分位数の定義は他にもいくつかある。

<四分位範囲，四分位偏差>


第3四分位数から第1四分位数を引いたものを 四分位範囲 といい，四分位範囲を2で割った値を 四分位偏差 という。

例1において，第1四分位数 Q_1 は $Q_1 = 4$ ，第3四分位数 Q_3 は $Q_3 = 8$ である。
これより，四分位範囲は $Q_3 - Q_1 = 8 - 4 = 4$ ，四分位偏差は $\frac{Q_3 - Q_1}{2} = 2$ である。

<箱ひげ図>

複数のデータの分布を比較するときに用いられる。
例えば，上の例2と例3の箱ひげ図は右のようになる。

なお，平均値を記入するときは+で記入する。
(箱ひげ図を90°回転して，縦に表示することもある。)



基本 例題 174 中央値がとりうる値



学生 9 人を対象に試験を行った結果、それぞれ 50, 57, 60, 42, x , 73, 80, 35, 68 点だった。0 以上 100 以下の整数 x の値がわからないとき、このデータの中央値として何通りの値がありうるか。 [摂南大]

基本 172

指針▷ 中央値の問題は **小さい方から順にデータを並べる** ことが第一である。……… **!**
この例題では、データの大きさが 9 であるから、5 番目の値が中央値となる。




CHART 中央値 データの値を、小さい方から順に並べて判断

解答

データの大きさが 9 であるから、中央値は小さい方から 5 番目の値である。

x 以外の値を小さい方から順に並べると

! 35, 42, 50, 57, 60, 68, 73, 80

この 8 個のデータにおいて、小さい方から 4 番目の値は 57, 5 番目の値が 60 であるから

[1] $0 \leq x \leq 56$ のとき

57 が 5 番目となる。

[2] $x = 57$ のとき

57 ($=x$) が 5 番目となる。

[3] $57 < x < 60$ のとき、 x のとりうる値は 58, 59

x が 5 番目となる。

[4] $x = 60$ のとき

60 ($=x$) が 5 番目となる。

[5] $60 < x \leq 100$ のとき

60 が 5 番目となる。

以上から、中央値の値としてありうるのは、

57, 58, 59, 60

の 4 通り。

◀ [1] と [2] をまとめて
 $0 \leq x \leq 57$ としてもよい。

◀ [4] と [5] をまとめてもよい。

練習 ③ 174 次のデータは 10 人の生徒のある教科のテストの得点である。ただし、 x の値は正の整数である。


43, 55, x , 64, 36, 48, 46, 71, 65, 50 (単位は点)

x の値がわからないとき、このデータの中央値として何通りの値がありうるか。


(p.292 EX125)



ある高校 3 年生 1 クラスの生徒 40 人について、ハンドボール投げの飛距離のデータを取った。
[図 1] は、このクラスで最初にとったデータのヒストグラムである。 [類 センター試験]



- (1) この 40 人のデータの第 3 四分位数が含まれる階級を次の ①～③ から 1 つ選べ。
- ① 20 m 以上 25 m 未満
 - ② 25 m 以上 30 m 未満
 - ③ 30 m 以上 35 m 未満
- (2) このデータを箱ひげ図にまとめたとき、[図 1] のヒストグラムと矛盾するものを次の ④～⑨ から 4 つ選べ。




- (3) 後日、このクラスでハンドボール投げの記録を取り直した。次に示した A～D は、最初にとった記録から今回の記録への変化の分析結果を記述したものである。a～d の各々が今回取り直したデータの箱ひげ図となる場合に、⑩～⑬ の組合せのうち分析結果と箱ひげ図が矛盾するものを 2 つ選べ。

- ⑩ A - a ⑪ B - b ⑫ C - c ⑬ D - d

A：どの生徒の記録も下がった。 B：どの生徒の記録も伸びた。

C：最初にとったデータで上位 $\frac{1}{3}$ に入るすべての生徒の記録が伸びた。

D：最初にとったデータで上位 $\frac{1}{3}$ に入るすべての生徒の記録は伸び、下位 $\frac{1}{3}$ に入るすべての生徒の記録は下がった。



基本 例題 175 四分位数, 四分位範囲



次のデータは, A 班 10 人と B 班 9 人の 7 日間の勉強時間の合計を調べたものである。

A 班 5, 15, 17, 11, 18, 22, 12, 9, 14, 4

B 班 2, 16, 13, 19, 6, 3, 10, 8, 7 (単位は時間)

- (1) それぞれのデータの範囲を求め, それに基づいて, データの散らばりの度合いを比較せよ。
- (2) それぞれのデータの第 1 四分位数 Q_1 , 第 2 四分位数 Q_2 , 第 3 四分位数 Q_3 を求めよ。
- (3) それぞれのデータの四分位範囲, 四分位偏差を求めよ。また, 四分位範囲に基づいて, データの散らばりの度合いを比較せよ。

p.274 基本事項 ①

指針 ▷ (1) データの範囲は, データの最大値と最小値の差。

- (2) p.274 の解説〈四分位数の求め方〉の手順で, 第 2 四分位数 (中央値), 第 1 四分位数, 第 3 四分位数の順に求める。まずは, **データを小さい方から順に並べる。…** [!]

- (3) 四分位範囲は $Q_3 - Q_1$, 四分位偏差は $\frac{Q_3 - Q_1}{2}$

解 答

- (1) A 班のデータの範囲は $22 - 4 = 18$ (時間)

B 班のデータの範囲は $19 - 2 = 17$ (時間)

よって, A 班の方が範囲が大きい。

ゆえに, A 班の方が散らばりの度合いが大きいと考えられる。

- (2) A 班のデータを小さい方から順に並べると

[!] 4, 5, 9, 11, 12, 14, 15, 17, 18, 22

下位のデータ

上位のデータ

← 4, 5, 9, 11, 12, 14, 15, 17, 18, 22

よって $Q_2 = \frac{12+14}{2} = 13$ (時間),

$Q_1 = 9$ (時間), $Q_3 = 17$ (時間)

B 班のデータを小さい方から順に並べると

[!] 2, 3, 6, 7, 8, 10, 13, 16, 19

下位のデータ

上位のデータ

← 2, 3, 6, 7, 8, 10, 13, 16, 19

ゆえに $Q_2 = 8$ (時間), $Q_1 = \frac{3+6}{2} = 4.5$ (時間),

$Q_3 = \frac{13+16}{2} = 14.5$ (時間)

- (3) A 班のデータの四分位範囲は $Q_3 - Q_1 = 8$ (時間), 四分位偏差は $\frac{8}{2} = 4$ (時間)

B 班のデータの四分位範囲は $Q_3 - Q_1 = 10$ (時間), 四分位偏差は $\frac{10}{2} = 5$ (時間)

よって, B 班の方が四分位範囲が大きい。

ゆえに, B 班の方が散らばりの度合いが大きいと考えられる。

練習 上の例題の A 班, B 班を合わせた大きさ 19 のデータの範囲, 四分位偏差を求めよ。

補足
事項

データの分析と代表値

次の表は、2008 年から 2013 年までの乗用車の新車登録台数を月別にまとめたものである。この表のデータから何が分析できるだろうか、ということを考えてみよう。

	1 月	2 月	3 月	4 月	5 月	6 月	7 月	8 月	9 月	10 月	11 月	12 月	合計
2008 年	32	43	61	31	30	36	38	26	40	31	30	25	423
2009 年	26	32	46	24	24	32	37	26	41	34	37	32	391
2010 年	32	40	58	30	30	38	42	37	40	25	26	24	422
2011 年	26	34	36	15	20	29	31	27	39	32	32	29	350
2012 年	36	45	64	31	34	43	45	32	38	30	32	28	458
2013 年	33	41	57	31	31	38	40	31	45	35	38	36	456


単位：万台

出典：日本自動車工業会（2014）『自動車統計月報』などより作成

[センター試験から抜粋]

それぞれの数字を見ただけではわからなくても、合計を見ると、2011 年が最も少ないことがわかる。2011 年は東日本大震災が 3 月に起きた年である。そこで、2011 年の各月の台数を見ると、3 月、4 月は特に他の年の半分程度しかない。これは大震災の影響といってよいだろう。

このように、合計もデータを比較する上での代表値として十分に役立つといえる。更にデータの傾向を調べようとするときに、箱ひげ図が役に立つ。例えば、下の箱ひげ図は上の表をもとに作成したものである。



[センター試験から抜粋]

この箱ひげ図を見ると、最大値、最小値において、2011 年のデータが突出して小さいことがわかる。ここからも、2011 年は何か特別な年であったことが窺える。このように、数字だけを見るより、箱ひげ図で視覚的に比較した方がよりわかりやすいと感じる人が多いだろう。しかし、箱ひげ図だけでは、2011 年が特別な年であったことがわかって、細かいことはわからない。ただし、表のデータを見ると、3 月、4 月が特に少なく、この時期に何かがあったことがわかる。データの代表値をもとに分析を行うことが多いが、逆に失われてしまう情報があることには留意しておきたい。

指針▷ 箱ひげ図からは、データの最大値、最小値、四分位数 Q_1 , Q_2 , Q_3 を読み取ることができる。

箱ひげ図



- (1) 40 人のデータで Q_3 は大きい方から 10 番目の記録と 11 番目の記録の平均である。
- (2) ④～⑨ について、データの最大値、最小値、中央値が含まれる階級は同じである。よって、第 1 四分位数、第 3 四分位数について調べる。
- (3) A～D を踏まえて、取り直す前と後のデータの最大値、最小値などの変化を考える。

解答

- (1) ヒストグラムより、大きい方から 10 番目の記録と 11 番目の記録は 25 m 以上 30 m 未満の階級に含まれることがわかるから、第 3 四分位数もこの階級に含まれる。
よって ②
- (2) (1) から、[図 1] のヒストグラムと矛盾するのは ④, ⑥, ⑦
また、[図 1] のヒストグラムより、小さい方から 10 番目の記録と 11 番目の記録は 15 m 以上 20 m 未満の階級に含まれることがわかるから、第 1 四分位数もこの階級に含まれる。このことと矛盾するのは ⑥, ⑦, ⑨
したがって、[図 1] のヒストグラムと矛盾するのは ④, ⑥, ⑦, ⑨
- (3) ⑩ a の箱ひげ図は最初のデータよりも第 1 四分位数が大きくなっているから、矛盾している。
⑪ b の箱ひげ図は最初のデータよりも最大値、第 3 四分位数、中央値、第 1 四分位数、最小値がすべて大きくなっているから、矛盾しているとはいえない。
⑫ c の箱ひげ図は最初のデータよりも最大値が小さくなっているから、矛盾している。
⑬ d の箱ひげ図は最初のデータよりも最大値と第 3 四分位数が大きくなっており、第 1 四分位数と最小値が小さくなっているから、矛盾しているとはいえない。
よって、分析結果と箱ひげ図が矛盾するものは ⑩, ⑫


練習

③ 176

右の図は、ある学校の 1 年生、2 年生各 200 人の身長データの箱ひげ図である。

この箱ひげ図から読み取れることとして、正しいものを次の ①～⑤ からすべて選べ。

- ① 185 cm より大きい生徒が 1 年生にはいるが、2 年生にはいない。
- ② 170 cm 以上の生徒が 1 年生では 100 人以下であるが、2 年生では 100 人以上いる。
- ③ 165 cm 以下の生徒がどちらの学年にも 50 人より多くいる。
- ④ 175 cm 以下の生徒は 1 年生では 150 人より多くいるが、2 年生では 150 人以下である。
- ⑤ 1 年生のデータの範囲は、2 年生のデータの範囲より 20 cm 以上大きい。





次のデータは、ある商品 A, B の 5 日間の売り上げ個数である。

A 5, 7, 4, 3, 6 B 4, 6, 8, 3, 9 (単位は個)

A, B の変量をそれぞれ x, y とするとき、次の問いに答えよ。

- (1) x, y のデータの平均値, 分散, 標準偏差をそれぞれ求めよ。ただし、標準偏差については小数第 2 位を四捨五入せよ。
- (2) x, y のデータについて、標準偏差によってデータの平均値からの散らばりの度合いを比較せよ。

p.279 基本事項 ①

指針▷ (1) 変量 x のデータが $x_1, x_2, \dots, x_n$ で、その平均値が $\bar{x}$ のとき、分散 s^2 は

① $s^2 = \overline{x^2} - (\bar{x})^2$

② $s^2 = \frac{1}{n} \{ (x_1 - \bar{x})^2 + (x_2 - \bar{x})^2 + \dots + (x_n - \bar{x})^2 \}$ ← 定義に基づいて計算

(2) 標準偏差(分散)が大きいことは、データの平均値の周りの散らばり方が大きいことの 1 つの目安である。

解 答

(1) x, y のデータの平均値をそれぞれ $\bar{x}, \bar{y}$ とすると

$\bar{x} = \frac{1}{5}(5+7+4+3+6) = 5$ (個), $\bar{y} = \frac{1}{5}(4+6+8+3+9) = 6$ (個) ◀ 平均値はともに整数。

x, y のデータの分散をそれぞれ s_x^2, s_y^2 とすると

$s_x^2 = \frac{1}{5}(5^2+7^2+4^2+3^2+6^2) - 5^2 = 2$ ◀ $\frac{1}{5}\{(5-5)^2+(7-5)^2+(4-5)^2+(3-5)^2+(6-5)^2\}$ でもよい。

$s_y^2 = \frac{1}{5}(4^2+6^2+8^2+3^2+9^2) - 6^2 = 5.2$ ◀ $\frac{1}{5}\{(4-6)^2+(6-6)^2+(8-6)^2+(3-6)^2+(9-6)^2\}$ でもよい。

よって、標準偏差は $s_x = \sqrt{2} \div 1.4$ (個), $s_y = \sqrt{5.2} \div 2.3$ (個) ◀ $(2.25)^2 = 5.0625$

(2) (1) から $s_y > s_x$ $(2.3)^2 = 5.29$

ゆえに、 y のデータの方が散らばりの度合いが大きい。

検討 分散の計算 指針 ① を使うか、指針 ② を使うか

各データに関する 2 乗の計算がらくかどうかで判断する。例えば、各データの値が 124, 131, …… でその平均が 126 であった場合、指針 ① を利用すると $124^2, 131^2$ といった計算をしなければならないが、指針 ② を利用すると $(124-126)^2 = (-2)^2, (131-126)^2 = 5^2$ というように、簡単に求められる。

製品の 重さ(g)	個 数	
	A 工場	B 工場
3.6	3	0
3.7	4	1
3.8	6	2
3.9	0	6
4.0	11	8
4.1	6	13
計	30	30

練習

右の表は、A 工場、B 工場の同じ規格の製品 30 個の重さを測った結果である。

- (1) 両工場のデータについて、平均値, 標準偏差をそれぞれ求めよ。ただし、小数第 3 位を四捨五入せよ。
- (2) 両工場のデータについて、標準偏差によってデータの平均値からの散らばりの度合いを比較せよ。

② 177

21 分散と標準偏差, 相関係数

基本事項

① 分散と標準偏差

変量 x についてのデータの値が, n 個の値 $x_1, x_2, \dots, x_n$ であるとし, $x_1, x_2, \dots, x_n$ の平均値を $\bar{x}$ とする。

① 分散: s^2

偏差の 2 乗の平均値であり

$$s^2 = \frac{1}{n} \{ (x_1 - \bar{x})^2 + (x_2 - \bar{x})^2 + \dots + (x_n - \bar{x})^2 \}$$

また, $s^2 = \overline{x^2} - (\bar{x})^2$ で計算できる。

↑ $(x^2 \text{ のデータの平均値}) - (x \text{ のデータの平均値})^2$

② 標準偏差

分散の正の平方根であり

$$\begin{aligned} s &= \sqrt{\frac{1}{n} \{ (x_1 - \bar{x})^2 + (x_2 - \bar{x})^2 + \dots + (x_n - \bar{x})^2 \}} \\ &= \sqrt{\overline{x^2} - (\bar{x})^2} \end{aligned}$$

解説

<偏差>

変量 x の n 個の各値 $x_1, x_2, \dots, x_n$ と平均値 $\bar{x}$ の差 $x_1 - \bar{x}, x_2 - \bar{x}, \dots, x_n - \bar{x}$ をそれぞれ $x_1, x_2, \dots, x_n$ の平均値からの **偏差** という。

<分散>

分散は, データの散らばりの度合いを表す量である。分散が小さいことは, データの平均値の周りの散らばり方が小さいことの 1 つの目安である。

分散 s^2 の式は次のように変形される。

$$\begin{aligned} s^2 &= \frac{1}{n} \{ (x_1 - \bar{x})^2 + (x_2 - \bar{x})^2 + \dots + (x_n - \bar{x})^2 \} \\ &= \frac{1}{n} \{ (x_1^2 + x_2^2 + \dots + x_n^2) - 2x_1\bar{x} - 2x_2\bar{x} - \dots - 2x_n\bar{x} + (\bar{x})^2 + (\bar{x})^2 + \dots + (\bar{x})^2 \} \\ &= \frac{1}{n} \{ (x_1^2 + x_2^2 + \dots + x_n^2) - 2\bar{x}(x_1 + x_2 + \dots + x_n) + n(\bar{x})^2 \} \\ &= \frac{1}{n} (x_1^2 + x_2^2 + \dots + x_n^2) - 2\bar{x} \cdot \frac{1}{n} (x_1 + x_2 + \dots + x_n) + (\bar{x})^2 \\ &= \overline{x^2} - 2\bar{x} \cdot \bar{x} + (\bar{x})^2 = \overline{x^2} - (\bar{x})^2 \end{aligned}$$

↑ $\overline{x^2}$ は x^2 のデータ $x_1^2, x_2^2, \dots, x_n^2$ の平均値を表す。

<標準偏差>

分散 s^2 の単位は, (変量の測定単位)² となってしまう。そこで, 測定単位と一致させるために, その平方根 $\sqrt{s^2}$ を散らばりの度合いを表す量として用いることも多い。

例 測定単位 m のとき, 分散の単位は m^2 , 標準偏差の単位は m

基本

例題 179

データの修正による平均値・分散の変化

次のデータは、ある都市のある年の月ごとの最高気温を並べたものである。

5, 4, 8, 12, 17, 24, 27, 28, 22, 30, 9, 6 (単位は℃)

- (1) このデータの平均値を求めよ。
- (2) このデータの中で入力ミスが見つかった。30℃となっている月の最高気温は正しくは18℃であった。この入力ミスを修正すると、このデータの平均値は修正前より何℃減少するか。
- (3) このデータの中で入力ミスが見つかった。正しくは6℃が10℃、30℃が26℃であった。この入力ミスを修正すると、このデータの平均値はア□し、分散はイ□する。
- ア□, イ□に当てはまるものを次の①, ②, ③から選べ。

- ① 修正前より増加
- ② 修正前より減少
- ③ 修正前と一致

基本 177

指針▷ (2), (3)ア $\text{平均値} = \frac{\text{データの総和}}{\text{データの大きさ}}$ 平均値の変化はデータの総和の変化に注目。

(3)イ $\text{分散} = \frac{\text{偏差の2乗の総和}}{\text{データの大きさ}}$ 分散の変化は偏差の2乗の総和の変化に注目。

解 答

- (1) $\frac{1}{12}(5+4+8+12+17+24+27+28+22+30+9+6)=16\text{ (℃)}$
- (2) データの総和は12℃減少するから、データの平均値は修正前より $\frac{12}{12}=1\text{ (℃)}$ 減少する。
- (3) ア $6+30=10+26$ であるから、データの総和は変化せず、平均値は修正前と一致する。よって ③
- イ (1), ア より、修正後のデータの平均値は16℃であるから、修正した2つのデータの平均値からの偏差の2乗の和は
- 修正前： $(6-16)^2+(30-16)^2=296$
- 修正後： $(10-16)^2+(26-16)^2=136$
- ゆえに、偏差の2乗の和は減少するから、分散は修正前より減少する。よって ②

◀修正前のデータの総和を X とすると、修正前の平均値は $\frac{X}{12}\text{℃}$ で、修正後の平均値は $\frac{X-12}{12}=\frac{X}{12}-1\text{ (℃)}$

◀平均値が修正前と修正後で一致しているから、修正していない10個のデータについては、平均値からの偏差の2乗の値に変化はない。

練習

③ 179

次のデータは、ある都市のある年の月ごとの最低気温を並べたものである。

-12, -9, -3, 3, 10, 17, 20, 19, 15, 7, 1, -8 (単位は℃)

- (1) このデータの平均値を求めよ。
- (2) このデータの中で入力ミスが見つかった。正しくは-3℃が-1℃、3℃が2℃、19℃が18℃であった。この入力ミスを修正すると、このデータの平均値はア□し、分散はイ□する。
- ア□, イ□に当てはまるものを上の例題の①, ②, ③から選べ。

基本 例題 178 平均値・分散 … 2つのデータを合わせる



ある集団は A と B の 2 つのグループで構成されている。データを集計したところ、それぞれのグループの個数、平均値、分散は右の表のようになった。このとき、集団全体の平均値と分散を求めよ。

グループ	個数	平均値	分散
A	20	16	24
B	60	12	28

[立命館大]

基本 177

5章

21

分散と標準偏差、相関係数

指針▷ データ $x_1, x_2, \dots, x_n$ の平均値を $\bar{x}$, 分散を s_x^2 とすると,

$$(\text{公式}) \quad s_x^2 = \overline{x^2} - (\bar{x})^2$$

が成り立つ。公式を利用して、まず、それぞれのデータの 2 乗の総和を求め、再度、公式を適用すれば、集団全体の分散は求められる。

この方針で求める際、それぞれのデータの値を文字で表すと考えやすい。下の解答では、A, B のデータの値をそれぞれ $x_1, x_2, \dots, x_{20}; y_1, y_2, \dots, y_{60}$ として考えている。なお、慣れてきたら、データの値を文字などで表さずに、**別解** のようにして求めてもよい。

解 答

集団全体の 平均値は $\frac{20 \times 16 + 60 \times 12}{20 + 60} = 13$

◀ 集団全体の総和は $20 \times 16 + 60 \times 12$

A の変量を x とし、データの値を $x_1, x_2, \dots, x_{20}$ とする。

また、B の変量を y とし、データの値を $y_1, y_2, \dots, y_{60}$ とする。

x, y のデータの平均値をそれぞれ $\bar{x}, \bar{y}$ とし、分散をそれぞれ s_x^2, s_y^2 とする。

$s_x^2 = \overline{x^2} - (\bar{x})^2$ より、 $\overline{x^2} = s_x^2 + (\bar{x})^2$ であるから

$$x_1^2 + x_2^2 + \dots + x_{20}^2 = 20 \times (24 + 16^2) = 160 \times 35 \quad \leftarrow \overline{x^2} = \frac{1}{20} (x_1^2 + x_2^2 + \dots + x_{20}^2)$$

$s_y^2 = \overline{y^2} - (\bar{y})^2$ より、 $\overline{y^2} = s_y^2 + (\bar{y})^2$ であるから

$$y_1^2 + y_2^2 + \dots + y_{60}^2 = 60 \times (28 + 12^2) = 240 \times 43$$

よって、集団全体の 分散は

$$\begin{aligned} & \frac{1}{20+60} (x_1^2 + x_2^2 + \dots + x_{20}^2 + y_1^2 + y_2^2 + \dots + y_{60}^2) - 13^2 \\ &= \frac{160 \times 35 + 240 \times 43}{80} - 169 = 30 \end{aligned}$$

↗ 集団全体の平均値は 13

別解 集団全体の 平均値は $\frac{20 \times 16 + 60 \times 12}{20 + 60} = 13$

A のデータの 2 乗の平均値は $24 + 16^2$ であり、B のデータの 2 乗の平均値は $28 + 12^2$ であるから、集団全体の 分散は

$$\frac{20 \times (24 + 16^2) + 60 \times (28 + 12^2)}{20 + 60} - 13^2 = \frac{160 \times 35 + 240 \times 43}{80} - 169 = 30$$

練習 12 個のデータがある。そのうちの 6 個のデータの平均値は 4、標準偏差は 3 であり、残りの 6 個のデータの平均値は 8、標準偏差は 5 である。

③ 178

(1) 全体の平均値を求めよ。

(2) 全体の分散を求めよ。

[広島工大]

基本 例題 180 変量を変換したときの平均値・分散



変量 x のデータの平均値 $\bar{x}$ が $\bar{x}=21$, 分散 s_x^2 が $s_x^2=12$ であるとする。このとき、次の式によって得られる新しい変量 y のデータについて、平均値 $\bar{y}$, 分散 s_y^2 , 標準偏差 s_y を求めよ。

ただし、 $\sqrt{3}=1.73$ とし、標準偏差は小数第 2 位を四捨五入して、小数第 1 位まで求めよ。

- (1) $y=x-5$
- (2) $y=3x$
- (3) $y=-2x+3$
- (4) $y=\frac{x-21}{2\sqrt{3}}$

p.283 基本事項 ① (重要 185)

指針▷ a, b は定数とする。変量 x のデータから $y=ax+b$ によって新しい変量 y のデータが得られるとき、 x, y のデータの平均値をそれぞれ $\bar{x}, \bar{y}$, 分散をそれぞれ s_x^2, s_y^2 , 標準偏差をそれぞれ s_x, s_y とすると

① $\bar{y}=a\bar{x}+b$

② $s_y^2=a^2s_x^2$

③ $s_y=|a|s_x$

が成り立つ。この ①, ②, ③ を利用すればよい。

補足 上の ①, ② は、p.283 基本事項 ① の $x=cu+x_0$ において、 x を y , c を a , u を x , x_0 を b におき換えたものである。

解 答

(1)	$\bar{y}=\bar{x}-5=21-5=16$ $s_y^2=1^2\times s_x^2=12$ $s_y=1\times s_x=2\sqrt{3}\div 3.5$	◀ $2\times 1.73=3.46$
(2)	$\bar{y}=3\bar{x}=3\times 21=63$ $s_y^2=3^2\times s_x^2=9\times 12=108$ $s_y=3s_x=3\times 2\sqrt{3}=6\sqrt{3}\div 10.4$	◀ $6\times 1.73=10.38$
(3)	$\bar{y}=-2\bar{x}+3=-2\times 21+3=-39$ $s_y^2=(-2)^2s_x^2=4\times 12=48$ $s_y= -2 s_x=2\times 2\sqrt{3}=4\sqrt{3}\div 6.9$	◀ $4\times 1.73=6.92$
(4)	$\bar{y}=\frac{\bar{x}-21}{2\sqrt{3}}=\frac{21-21}{2\sqrt{3}}=0$ $s_y^2=\frac{s_x^2}{(2\sqrt{3})^2}=\frac{12}{12}=1$ $s_y=\frac{s_x}{2\sqrt{3}}=\frac{2\sqrt{3}}{2\sqrt{3}}=1$	注意 (3) の s_y は (1) の s_y の 2 倍であるが、(1) の「3.5」は四捨五入された値のため、(3) の s_y を $3.5\times 2=7.0$ としたら間違い。

参考 (4) は変量 x を標準化したものである。

練習 ②180 ある変量のデータがあり、その平均値は 50, 標準偏差は 15 である。そのデータを修正して、各データの値を 1.2 倍して 5 を引いたとき、修正後の平均値と標準偏差を求めよ。

基本事項

1 変量の変換

変量 x のデータの平均を $\bar{x}$ 、標準偏差を s_x とし、 $u = \frac{x - x_0}{c}$ (x_0, c は定数) で定められる変量 u のデータの平均値を $\bar{u}$ 、標準偏差を s_u とする。

① 平均の変換 $\bar{x} = c\bar{u} + x_0 \quad \left(\bar{u} = \frac{\bar{x} - x_0}{c}\right)$

② 分散・標準偏差の変換

分散は $s_x^2 = c^2 s_u^2 \quad \left(s_u^2 = \frac{1}{c^2} s_x^2\right)$ 標準偏差は $s_x = |c| s_u \quad \left(s_u = \frac{1}{|c|} s_x\right)$

解 説

<変量の変換>

データの大きさを n として、変量 x の値を $x_1, x_2, \dots, x_n$ とする。また $x_k = cu_k + x_0$ ($k=1, 2, \dots, n$) とすると、上の ①, ② は下のように証明できる。

$$\begin{aligned} \text{①} \quad \bar{x} &= \frac{1}{n}(x_1 + x_2 + \dots + x_n) = \frac{1}{n}\{(cu_1 + x_0) + (cu_2 + x_0) + \dots + (cu_n + x_0)\} \\ &= \frac{1}{n}\{c(u_1 + u_2 + \dots + u_n) + \underbrace{(x_0 + x_0 + \dots + x_0)}_{n \text{ 個}}\} \\ &= c \times \frac{1}{n}(u_1 + u_2 + \dots + u_n) + x_0 \\ &= c\bar{u} + x_0 \end{aligned}$$

$$\begin{aligned} \text{②} \quad s_x^2 &= \frac{1}{n}\{(x_1 - \bar{x})^2 + (x_2 - \bar{x})^2 + \dots + (x_n - \bar{x})^2\} \\ &= \frac{1}{n}\{[(cu_1 + x_0) - (c\bar{u} + x_0)]^2 + [(cu_2 + x_0) - (c\bar{u} + x_0)]^2 + \dots \\ &\quad + [(cu_n + x_0) - (c\bar{u} + x_0)]^2\} \\ &= \frac{1}{n}\{c^2(u_1 - \bar{u})^2 + c^2(u_2 - \bar{u})^2 + \dots + c^2(u_n - \bar{u})^2\} \\ &= c^2 s_u^2 \end{aligned}$$

このように、関係式 $x = cu + x_0$ によって変量 x を別の変量 u に変えることを、変量の変換という。

例 変量の変換 $u = \frac{x - x_0}{c}$ において、 $x_0 = \bar{x}$ 、 $c = s_x$ とする。

このとき $\bar{u} = \frac{\bar{x} - \bar{x}}{s_x} = 0$ 、 $s_u = \frac{1}{|s_x|} s_x = 1$ ($s_x > 0$) この u を x の標準化という。

参考 標準化に関連する値の中で、代表的なものとして偏差値があげられる。

複数教科の試験を受けた場合、各教科の平均点が異なることが多いため、得点のみで教科間の実力の差を見極めることは難しい。このようなとき、偏差値を用いれば各教科の平均点が異なっても教科間の実力の差が比較しやすくなる。

得点 x の偏差値 y は、平均値 $\bar{x}$ と標準偏差 s_x を用いて、次のように定義される。

$$y = 10 \times \frac{x - \bar{x}}{s_x} + 50 \quad \leftarrow x \text{ を標準化し、更に変換したものが } y \text{ となっている。}$$

基本事項

① データの相関


2つの変量 x, y があり、そのデータの大きさがともに n 個であり、
 $x_1, x_2, \dots, x_n \quad y_1, y_2, \dots, y_n$ とする。

① 散布図

右の図のように、 x と y の間の関係を見やすくするために、 x, y の値の組

$$(x_k, y_k) \quad k=1, 2, \dots, n$$

を座標とする点を座標平面上にとったもの。



② 2つの変量のデータにおいて、一方が増えると他方もある傾向が認められるとき、2つの変量の間に **正の相関関係** があるという。逆に、一方が増えると他方が減る傾向が認められるとき、2つの変量の間に **負の相関関係** があるという。どちらの傾向も認められないときは、**相関関係がない** という。

③ 共分散 s_{xy} x の偏差と y の偏差の積 $(x_k - \bar{x})(y_k - \bar{y})$ の平均値。

$$s_{xy} = \frac{1}{n} \{ (x_1 - \bar{x})(y_1 - \bar{y}) + (x_2 - \bar{x})(y_2 - \bar{y}) + \dots + (x_n - \bar{x})(y_n - \bar{y}) \}$$

④ 相関係数 r


相関関係の目安となる数値。 x, y の標準偏差をそれぞれ s_x, s_y とするとき

$$r = \frac{s_{xy}}{s_x s_y} = \frac{(x_1 - \bar{x})(y_1 - \bar{y}) + (x_2 - \bar{x})(y_2 - \bar{y}) + \dots + (x_n - \bar{x})(y_n - \bar{y})}{\sqrt{\{ (x_1 - \bar{x})^2 + (x_2 - \bar{x})^2 + \dots + (x_n - \bar{x})^2 \} \{ (y_1 - \bar{y})^2 + (y_2 - \bar{y})^2 + \dots + (y_n - \bar{y})^2 \}}}$$

- [1] $r=1$ のとき、散布図の点は右上がりの直線に沿って分布する。
- [2] $r=-1$ のとき、散布図の点は右下がりの直線に沿って分布する。
- [3] r の値が 0 に近いとき、直線的な相関関係はない。


解説

<散布図と相関関係の分類>




正の相関関係

点の分布が、
右上がりの
直線に近い。



負の相関関係

点の分布が、
右下がりの
直線に近い。



相関関係なし


<共分散、相関係数>

共分散 $s_{xy} > 0$ のとき、右の図の「+」の部分にある点 (x_k, y_k) が多い。→ 正の相関関係

共分散 $s_{xy} < 0$ のとき、右の図の「-」の部分にある点 (x_k, y_k) が多い。→ 負の相関関係

相関係数 r については $-1 \leq r \leq 1$ であり、次のようになる。

$$r > 0 \iff s_{xy} > 0 \quad r < 0 \iff s_{xy} < 0$$



基本 例題 181 平均値・分散の計算(変量の変換利用)



次の変量 x のデータについて、以下の問いに答えよ。

726, 814, 798, 750, 742, 766, 734, 702

(1) $y = x - 750$ とおくことにより、変量 x のデータの平均値 $\bar{x}$ を求めよ。

(2) $u = \frac{x - 750}{8}$ とおくことにより、変量 x のデータの分散を求めよ。

基本 180

- 指針▷ (1) y のデータの平均を $\bar{y}$ とすると、 $\bar{y} = \bar{x} - 750$ すなわち $\bar{x} = \bar{y} + 750$ である。よって、まず $\bar{y}$ を求める。
- (2) x, u のデータの分散をそれぞれ s_x^2, s_u^2 とすると、 $s_x^2 = 8^2 s_u^2$ である。よって、まず、変量 x の各値に対応する、変量 u の値を求め、 s_u^2 を計算する。

解答

$$(1) \bar{y} = \frac{1}{8} \{(-24) + 64 + 48 + 0 + (-8) + 16 + (-16) + (-48)\} \\ = 4$$

$$\text{ゆえに } \bar{x} = \bar{y} + 750 = 754$$

(2) $u = \frac{x - 750}{8}$ とおくと、 u, u^2 の値は次のようになる。

x	726	814	798	750	742	766	734	702	計
y	-24	64	48	0	-8	16	-16	-48	32
u	-3	8	6	0	-1	2	-2	-6	4
u^2	9	64	36	0	1	4	4	36	154

よって、 u のデータの分散は

$$\overline{u^2} - (\bar{u})^2 = \frac{154}{8} - \left(\frac{4}{8}\right)^2 = \frac{76}{4} = 19$$

ゆえに、 x のデータの分散は

$$8^2 \times 19 = 1216$$

参考 上の例題(1)の「750」ように、平均値の計算を簡単にするためにとった値のことを **仮平均** という。仮平均を自分で設定する場合、計算がらくになるようなものを選ぶ。具体的には、各データとの差が小さくなる値(平均値に近いと予想される値)をとるとよい。

$$(1) \bar{x} = \frac{1}{8} (726 + \cdots + 702)$$

としても求められるが、解答の方が計算がらく。

$$\blacktriangleleft s_x^2 = 8^2 s_u^2$$

$\blacktriangleleft u = \frac{x - x_0}{c}$ の x_0 を仮平均という。

練習

次の変量 x のデータについて、以下の問いに答えよ。

514, 584, 598, 521, 605, 612, 577

(1) $y = x - 570$ とおくことにより、変量 x のデータの平均値 $\bar{x}$ を求めよ。

(2) $u = \frac{x - 570}{7}$ とおくことにより、変量 x のデータの分散を求めよ。



次の表は、学生 5 名の身長 x (cm) と体重 y (kg) を測定した結果である。 x と y の相関係数 r を求めよ。

	A	B	C	D	E
身長 x (cm)	181	167	173	169	165
体重 y (kg)	75	59	63	67	61

[藤田保健衛生大]

p.286 基本事項 ① 重要 185

指針▷ x, y のデータの標準偏差をそれぞれ s_x, s_y とし、 x と y の共分散を s_{xy} とするとき、相関

係数 r は、
$$r = \frac{s_{xy}}{s_x s_y} = \frac{(x-\bar{x})(y-\bar{y}) \text{ の和}}{\sqrt{\{(x-\bar{x})^2 \text{ の和}\} \times \{(y-\bar{y})^2 \text{ の和}\}}}$$
 で与えられる。

r を求めるには、 x, y のデータの平均 $\bar{x}, \bar{y}$ をまず求め、 $(x-\bar{x})^2$ の和、 $(y-\bar{y})^2$ の和、 $(x-\bar{x})(y-\bar{y})$ の和の順に計算していく。この際、下の解答のように表を作成して計算するとよい。

解 答

x, y のデータの平均をそれぞれ $\bar{x}, \bar{y}$ とすると

$$\bar{x} = 170 + \frac{1}{5}(11 - 3 + 3 - 1 - 5) = 171$$

$$\bar{y} = 65 + \frac{1}{5}(10 - 6 - 2 + 2 - 4) = 65$$

よって、次の表が得られる。

	$x-\bar{x}$	$y-\bar{y}$	$(x-\bar{x})^2$	$(y-\bar{y})^2$	$(x-\bar{x})(y-\bar{y})$
A	10	10	100	100	100
B	-4	-6	16	36	24
C	2	-2	4	4	-4
D	-2	2	4	4	-4
E	-6	-4	36	16	24
計			160	160	140

ゆえに、相関係数 r は

$$r = \frac{140}{\sqrt{160 \times 160}} = \frac{140}{160} = 0.875$$

- ◀ 仮平均 (p.285 参照) を 170 として計算。
- ◀ 仮平均を 65 として計算。

練習

① 183

下の表は、10 人の生徒に 30 点満点の 2 種類のテスト A, B を行った得点の結果である。テスト A, B の得点をそれぞれ x, y とするとき、 x と y の相関係数 r を求めよ。ただし、小数第 3 位を四捨五入せよ。

生徒番号	1	2	3	4	5	6	7	8	9	10
x	29	25	22	28	18	23	26	30	30	29
y	23	23	18	26	17	20	21	20	26	26

基本 例題 182 散布図と相関関係



次のような変量 x , y のデータがある。これらについて、散布図をかき、 x と y の間に相関関係があるかどうかを調べよ。また、相関関係がある場合には、正・負のどちらであるかをいえ。

(1)

x	1	3	8	5	4	6	2	9
y	2	2	6	7	3	5	3	8

(2)

x	38	46	20	48	18	27	11	33
y	12	15	25	11	30	21	38	30

(3)

x	1.3	3.3	4.9	2.2	5.7	3.6	2.7	4.0
y	2.6	4.2	2.0	1.3	4.2	1.2	4.1	3.6

p.286 基本事項 ①

指針▷ 変量 x , y について、組 (x, y) を座標とする点を平面上にとる。その際、目盛りは表す点がわかりやすくなるように入れる。

でき上がった散布図をみて、次のように判断する。




散布図の点が全体に **右上がりに分布** → **正の相関関係**

散布図の点が全体に **右下がりに分布** → **負の相関関係**

どちらの傾向もみられない → **相関関係がない**

解答

(1) [図] 正の相関関係がある。(2) [図] 負の相関関係がある。(3) [図] 相関関係はない。




練習

① 182

右の散布図は、30 人のクラスの漢字と英単語の 100 点満点で実施したテストの得点の散布図である。

(1) この散布図をもとにして、漢字と英単語の得点の間に相関関係があるかどうかを調べよ。また、相関関係がある場合には、正・負のどちらであるかをいえ。

(2) この散布図をもとにして、英単語の度数分布表を作成せよ。ただし、階級は「40 以上 50 未満」, …… , 「90 以上 100 未満」とする。



基本 例題 184 相関係数による分析



右の表は、10 名からなるある少人数クラスで、100 点満点で 2 回ずつ実施した数学と英語のテストの得点をまとめたものである。

番号	1 回目		2 回目	
	数学	英語	数学	英語
1	40	43	60	54
2	63	55	61	67
3	59	62	56	60
4	35	64	60	71
5	43	36	69	80
6	36	48	64	50
7	51	46	54	57
8	57	71	59	40
9	32	65	49	42
10	34	50	57	69

- (1) 数学と英語の得点の散布図を、1 回目、2 回目の各回についてかけ。
- (2) 1 回目の数学と英語の得点の相関係数を r_1 、2 回目の数学と英語の得点の相関係数を r_2 とするとき、値の組 (r_1, r_2) として正しいものを以下の①～④から 1 つ選べ。
- ① $(0.54, 0.20)$ ② $(-0.54, 0.20)$
③ $(0.20, 0.54)$ ④ $(0.20, -0.54)$


基本 182

指針▷ 与えられたデータから相関係数を選ぶ問題では、相関係数の組が与えられているから、直接計算をする必要はない。ここでは、(1)で散布図をかくから、それをもとに判断する。


参考 散布図において、点の配列にできるだけ合うように引いた直線を 回帰直線 という。

解 答

(1) 〔図〕 1 回目



2 回目



- (2) 2 回目の散布図より、2 回目の数学と英語の得点には正の相関関係があるから $r_2 > 0$
また、1 回目と 2 回目の散布図より、1 回目の方が 2 回目よりも相関が弱いから $|r_1| < |r_2|$
以上から、値の組は ③ $(0.20, 0.54)$

散布図において、点が右上がりの直線（右下がりの直線）上およびその近くに分布しているほど相関が強いといい、直線上ではなく広くばらついているほど相関が弱いという。

練習

③ 184

右の表は、2 つの変数 x, y のデータである。

- (1) これらのデータについて、 $0.72, -0.19, -0.85$ のうち、 x と y の相関係数に最も近いものはどれか。
- (2) 表の右端のデータの y の値を 68 に変更すると、 x と y の相関係数の絶対値は大きくなるか、それとも小さくなるか。

x	80	70	62	72	90	78
y	58	72	83	71	52	78

1 はずれ値


データには、他と比べて値が大きく異なる「はずれ値」とよばれるものが含まれることがある。例えば、次のデータ 5, 8, 8, 9, 10, 12, 15, 99 …… ①

に関し、平均値は 20.75, 中央値は 9.5 である。99 をはずれ値として除いて考えると、平均値は約 9.57 と大きく変化するが、中央値は 9 とあまり変化しない。

このように、平均値は中央値よりはずれ値の影響を受けやすい。

また、データ ① の範囲は $99 - 5 = 94$, 四分位範囲は $13.5 - 8 = 5.5$ である。はずれ値 99 を除いたデータの範囲は $15 - 5 = 10$, 四分位範囲は $12 - 8 = 4$ となり、四分位範囲の方がはずれ値の影響を受けにくいことがわかる。

データを扱うとき、はずれ値をどのように扱うのかは、その目的によって異なり、また、どのような統計量（平均値、中央値など）を考えるかも、目的によって異なってくる。



A: ①の箱ひげ図

B: ①から99を除いたデータの箱ひげ図

2 相関係数とはずれ値

相関係数もはずれ値の影響を受けやすい。

例えば、例題 182 (1) のデータに $(x, y) = (1, 15)$ を付け加えると、次のようになる。

(1)

x	1	3	8	5	4	6	2	9	1
y	2	2	6	7	3	5	3	8	15

相関係数は、およその値で 0.9 から 0.1 に変化する。



また、例題 182 (3) のデータに $(x, y) = (15.0, 15.0)$ を付け加えると次のようになる。

(3)

x	1.3	3.3	4.9	2.2	5.7	3.6	2.7	4.0	15.0
y	2.6	4.2	2.0	1.3	4.2	1.2	4.1	3.6	15.0

相関係数は、およその値で 0.3 から 0.9 に変化する。相関係数は 0.9 となるが、右の散布図から、強い正の相関関係があるとはいえない。

このことでもわかるように、相関係数だけで相関関係を判断するのは避け、はずれ値のことを念頭において散布図をかいて考えるべきである。



- ③125 30 人のクラスで 10 点満点のテストを行い, その結果は次の表の通りである。
- | | | | | | | | | | | | | |
|----|---|---|---|---|---|-----|-----|---|---|---|----|----|
| 得点 | 0 | 1 | 2 | 3 | 4 | 5 | 6 | 7 | 8 | 9 | 10 | 計 |
| 人数 | 0 | 0 | 2 | 4 | 5 | a | b | 2 | 3 | 4 | 3 | 30 |
- (1) $a+b$ の値を求めよ。
(2) 得点の平均値が 6 点のとき, a と b の値の組 (a, b) を求めよ。
(3) 得点の中央値が 5.5 点のとき, a と b の値の組 (a, b) を求めよ。
(4) 得点の中央値が 6 点のとき, a と b の値の組 (a, b) を求めよ。 [広島工大]
➡173,174

- ④126 変量 x の値を $x_1, x_2, \dots, x_n$ とする。このとき, ある値 t からの各値の偏差 $t-x_k$ ($k=1, 2, \dots, n$) の 2 乗の和を y とする。すなわち $y=(t-x_1)^2+(t-x_2)^2+\dots+(t-x_n)^2$ である。
このとき, y は $t=\bar{x}$ (x の平均値) のとき最小となることを示せ。 ➡177

- ③127 3 つの正の数 a, b, c の平均値が 14, 標準偏差が 8 であるとき, $a^2+b^2+c^2=^{\text{ア}}\square$, $ab+bc+ca=^{\text{イ}}\square$ である。 [立命館大]
➡177

- ③128 (1) 変量 x のデータの値が $x_1, x_2, \dots, x_n$ であるとし, その平均値を $\bar{x}$ とする。
新たにデータを得たとし, その値を x_{n+1} とする。 $x_1, x_2, \dots, x_n, x_{n+1}$ の平均値を $x_{n+1}, \bar{x}$ および n を用いて表せ。
(2) 右の 40 個のデータの平均値, 分散, 中央値を計算すると, それぞれ, ちょうど 40, 670, 35 であった。
新たにデータを得たとし, その値が 40 であった。このとき, 41 個のすべてのデータの平均値, 分散, 中央値を求めよ。ただし, 得られた値が整数でない場合は, 小数第 1 位を四捨五入せよ。 [類 広島大]
➡178

120	10	60	70	30	20	20	30	20	60
40	50	40	10	30	40	40	30	20	70
100	20	20	40	40	60	70	20	50	10
30	10	50	80	10	30	70	10	60	10

- HINT

126 t についての 2 次関数とみて, 平方完成する。
127 (イ) $(a+b+c)^2=a^2+b^2+c^2+2(ab+bc+ca)$ を利用する。
128 (2) 平均値は, (1) を利用する。分散については, 40 個のデータの値を $x_1, x_2, \dots, x_{40}$ として考える。

重要 例題 185 変量を変換したときの相関係数



2つの変量 x, y の3組のデータ $(x_1, y_1), (x_2, y_2), (x_3, y_3)$ がある。変量 x, y, xy の平均をそれぞれ $\bar{x}, \bar{y}, \overline{xy}$ とし, x, y の標準偏差をそれぞれ s_x, s_y , 共分散を s_{xy} とする。このとき, 次の問いに答えよ。

- (1) $s_{xy} = \overline{xy} - \bar{x} \cdot \bar{y}$ が成り立つことを示せ。
- (2) 変量 z を $z = 2y + 3$ とするとき, x と z の相関係数 r_{xz} は x と y の相関係数 r_{xy} に等しいことを示せ。

基本 180, 183

指針▷ (1) $s_{xy} = \frac{1}{3} \{ (x_1 - \bar{x})(y_1 - \bar{y}) + (x_2 - \bar{x})(y_2 - \bar{y}) + (x_3 - \bar{x})(y_3 - \bar{y}) \}$ の右辺を変形する。

(2) 変量 z を $z = ay + b$ とするとき, $\bar{z} = a\bar{y} + b, s_z = |a|s_y$ (p.284 指針参照) が成り立つ。このことと (1) の結果を利用する。

解答

$$\begin{aligned}
 (1) \quad s_{xy} &= \frac{1}{3} \{ (x_1 - \bar{x})(y_1 - \bar{y}) + (x_2 - \bar{x})(y_2 - \bar{y}) + (x_3 - \bar{x})(y_3 - \bar{y}) \} \\
 &= \frac{1}{3} \{ (x_1 y_1 + x_2 y_2 + x_3 y_3) - \bar{x}(y_1 + y_2 + y_3) - (x_1 + x_2 + x_3)\bar{y} + 3\bar{x} \cdot \bar{y} \} \\
 &= \frac{1}{3} (x_1 y_1 + x_2 y_2 + x_3 y_3) - \bar{x} \cdot \frac{y_1 + y_2 + y_3}{3} - \frac{x_1 + x_2 + x_3}{3} \cdot \bar{y} + \bar{x} \cdot \bar{y} \\
 &= \overline{xy} - \bar{x} \cdot \bar{y} - \bar{x} \cdot \bar{y} + \bar{x} \cdot \bar{y} = \overline{xy} - \bar{x} \cdot \bar{y}
 \end{aligned}$$

(2) x と z の共分散を s_{xz} とし, $z_k = 2y_k + 3$ ($k=1, 2, 3$) とする。

(1) から $s_{xz} = \overline{xz} - \bar{x} \cdot \bar{z}$

$$\begin{aligned}
 \text{ここで} \quad \overline{xz} &= \frac{1}{3} (x_1 z_1 + x_2 z_2 + x_3 z_3) = \frac{1}{3} \{ x_1 (2y_1 + 3) + x_2 (2y_2 + 3) + x_3 (2y_3 + 3) \} \\
 &= 2 \cdot \frac{1}{3} (x_1 y_1 + x_2 y_2 + x_3 y_3) + 3 \cdot \frac{x_1 + x_2 + x_3}{3} = 2\overline{xy} + 3\bar{x}
 \end{aligned}$$

$$\begin{aligned}
 \text{よって} \quad s_{xz} &= 2\overline{xy} + 3\bar{x} - \bar{x} \cdot (2\bar{y} + 3) = 2\overline{xy} - 2\bar{x} \cdot \bar{y} \\
 &= 2(\overline{xy} - \bar{x} \cdot \bar{y}) = 2s_{xy}
 \end{aligned}$$

z の標準偏差を s_z とすると, $s_z = 2s_y$ であるから

$$r_{xz} = \frac{s_{xz}}{s_x s_z} = \frac{2s_{xy}}{s_x \cdot 2s_y} = \frac{s_{xy}}{s_x s_y} = r_{xy}$$

参考 一般に2つの変量 x, y について, $s_{xy} = \overline{xy} - \bar{x} \cdot \bar{y}$ が成り立つ。

また, 変量 z を $z = ay + b$ とするとき, $s_{xz} = a s_{xy}$ が成り立つ。

練習

④ 185 変量 x の平均を $\bar{x}$ とする。2つの変量 x, y の3組のデータ $(x_1, y_1), (x_2, y_2), (x_3, y_3)$ があり, $\bar{x}=1, \bar{y}=2, \overline{x^2}=3, \overline{y^2}=10, \overline{xy}=4$ である。このとき, 以下の問いに答えよ。ただし, 相関係数については, $\sqrt{3}=1.73$ とし, 小数第2位を四捨五入せよ。

- (1) x と y の共分散 s_{xy} , 相関係数 r_{xy} を求めよ。
- (2) 変量 z を $z = -2x + 1$ とするとき, y と z の共分散 s_{yz} , 相関係数 r_{yz} を求めよ。

(p.293 EX130)


EXERCISES

20 データの代表値と散らばり, 21 分散と標準偏差, 相関係数

- ③129 次の表は、P 高校のあるクラス 20 人について、数学と国語のテストの得点をまとめたものである。数学の得点を変数 x 、国語の得点を変数 y で表し、 x 、 y の平均値をそれぞれ $\bar{x}$ 、 $\bar{y}$ で表す。ただし、表の数値はすべて正確な値であり、四捨五入されていないものとする。

生徒番号	x	y	$x - \bar{x}$	$(x - \bar{x})^2$	$y - \bar{y}$	$(y - \bar{y})^2$	$(x - \bar{x})(y - \bar{y})$
1	62	63	3.0	9.0	2.0	4.0	6.0
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$
20	57	63	-2.0	4.0	2.0	4.0	-4.0
合 計	A	1220	0.0	1544.0	0.0	516.0	-748.0
平 均	B	61.0	0.0	77.2	0.0	25.8	-37.4
中央値	57.5	62.0	-1.5	30.5	1.0	9.0	-14.0

- (1) A と B の値を求めよ。
 (2) 変数 x と変数 y の散布図として適切なものを、相関関係、中央値に注意して次の ①～④のうちから 1 つ選べ。



➡183, 184

- ④130 東京と N 市の 365 日の各日の最高気温のデータについて考える。
 N 市では温度の単位として摂氏 ($^{\circ}\text{C}$) のほかに華氏 ($^{\circ}\text{F}$) も使われている。華氏 ($^{\circ}\text{F}$) での温度は、摂氏 ($^{\circ}\text{C}$) での温度を $\frac{9}{5}$ 倍し、32 を加えると得られる。

したがって、N 市の最高気温について、摂氏での分散を X 、華氏での分散を Y とすると、 $\frac{Y}{X} = \text{ア}$ である。

東京 (摂氏) と N 市 (摂氏) の共分散を Z 、東京 (摂氏) と N 市 (華氏) の共分散を W とすると、 $\frac{W}{Z} = \text{イ}$ である。

東京 (摂氏) と N 市 (摂氏) の相関係数を U 、東京 (摂氏) と N 市 (華氏) の相関係数を V とすると、 $\frac{V}{U} = \text{ウ}$ である。

[類 センター試験]

➡180, 185

- HINT** 129 (1) 番号 1 の生徒の $x - \bar{x}$ から $\bar{x}$ が求められる。
 130 変数を変換したときの公式を利用する。